

سوال ۱: درخت تصمیم (تحلیلی)

قسمت الف: طراحی طبقه بند

در الگوریتم ID3، ابتدا می‌خواهیم ریشه (گره مادر - مرجع) را برای درخت تصمیم بدست آوریم. به همین منظور هر ویژگی را بعنوان یک گره در نظر می‌گیریم و سپس در این حالت میزان ابهامی از برچسب داده که برطرف می‌شود (آنتروپی) را بدست می‌آوریم. بدیهی است که در هر مرحله هر ویژگی که آنتروپی کمتری دارد (ابهام بیشتری را از ابهام گره بالایی برطرف کرده است) به عنوان گره در نظر می‌گیریم. جدول ۱، کلیه داده‌های آموزش را نشان می‌دهد.

| شماره | رنگ | تعداد پا | قد | محل زندگی | جاندار |
|-------|---------|----------|-------|-----------|--------|
| ۱ | قهوه‌ای | ۲ | بلند | خشکی | A |
| ۲ | قهوه‌ای | ۳ | کوتاه | خشکی | B |
| ۳ | سبز | ۲ | بلند | آب | B |
| ۴ | سبز | ۳ | بلند | آب | B |
| ۵ | قهوه‌ای | ۲ | کوتاه | آب | A |
| ۶ | قهوه‌ای | ۲ | بلند | آب | A |
| ۷ | قهوه‌ای | ۲ | کوتاه | خشکی | B |
| ۸ | سبز | ۲ | کوتاه | آب | A |
| ۹ | سبز | ۳ | بلند | آب | B |
| ۱۰ | قهوه‌ای | ۲ | بلند | خشکی | A |

جدول ۱: داده های آموزش

ابتدا آنتروپی باینری را به صورت زیر در نظر می‌گیریم:

$$H_{binary} = h_b(p) = p \log(p) + (1 - p) \log(1 - p)$$

به این ترتیب گره ریشه، ویژگی‌ای خواهد بود که کمترین آنتروپی را دارد.

$$H_{\text{رنگ}} = p_{\text{سبز}} H_{\text{سبز}} + p_{\text{قهوه‌ای}} H_{\text{قهوه‌ای}}$$

$$H_{\text{سبز}} = h_b\left(p_{\text{سبز}A}\right) = h_b\left(\frac{1}{4}\right) = 0.8113$$

$$H_{\text{قهوه‌ای}} = h_b(p_{\text{قهوه‌ای},A}) = h_b\left(\frac{1}{3}\right) = 0.9183$$

$$\rightarrow H_{\text{رنگ}} = \frac{4}{10}H_{\text{سبز}} + \frac{6}{10}H_{\text{قهوه‌ای}} = 0.8775$$

$$H_{\text{تعدادپا}} = p_2H_2 + p_3H_3$$

$$H_2 = h_b(p_{2,A}) = h_b\left(\frac{2}{7}\right) = 0.8631$$

$$H_3 = h_b(p_{3,A}) = h_b(1) = 0$$

$$\rightarrow H_{\text{تعدادپا}} = \frac{7}{10}H_2 + \frac{3}{10}H_3 = 0.6042$$

$$H_{\text{قد}} = p_{\text{بلند}}H_{\text{بلند}} + p_{\text{کوتاه}}H_{\text{کوتاه}}$$

$$H_{\text{بلند}} = h_b(p_{\text{بلند},A}) = h_b\left(\frac{1}{2}\right) = 1$$

$$H_{\text{کوتاه}} = h_b(p_{\text{کوتاه},A}) = h_b\left(\frac{1}{2}\right) = 1$$

$$\rightarrow H_{\text{قد}} = \frac{4}{10}H_{\text{کوتاه}} + \frac{6}{10}H_{\text{بلند}} = 1$$

$$H_{\text{محل زندگی}} = p_{\text{آب}}H_{\text{آب}} + p_{\text{خشکی}}H_{\text{خشکی}}$$

$$H_{\text{آب}} = h_b(p_{\text{آب},A}) = h_b\left(\frac{1}{2}\right) = 1$$


$$H_{\text{خشکی}} = h_b(p_{\text{خشکی},A}) = h_b\left(\frac{1}{2}\right) = 1$$

$$\rightarrow H_{\text{محل زندگی}} = \frac{6}{10}H_{\text{آب}} + \frac{4}{10}H_{\text{خشکی}} = 1$$

در نتیجه ویژگی ریشه درخت تصمیم، تعداد پا خواهد بود.

تعداد پا = گره ریشه

در این صورت درخت بعد از مرحله اول مطابق با تصویر ۱-۱ خواهد شد.



تصویر ۱-۱: درخت تصمیم بعد از اولین مرحله (تشخیص گره مادر)

حال داده‌های مربوط به هر شاخه را جدا می‌کنیم. همانطور که در تصویر ۱-۱ نیز مشاهده می‌شود، جانداران با ۳ پا همه از نوع B هستند. حال ادامه درخت را برای جانداران ۲ پا بدست می‌آوریم. به این ترتیب جدول ۲ جانداران ۲ پا را نشان می‌دهد.

| شماره | رنگ | قد | محل زندگی | جاندار |
|-------|---------|-------|-----------|--------|
| ۱ | قهوه‌ای | بلند | خشکی | A |
| ۳ | سبز | بلند | آب | B |
| ۵ | قهوه‌ای | کوتاه | آب | A |
| ۶ | قهوه‌ای | بلند | آب | A |
| ۷ | قهوه‌ای | کوتاه | خشکی | B |
| ۸ | سبز | کوتاه | آب | A |
| ۱۰ | قهوه‌ای | بلند | خشکی | A |

جدول ۲: داده‌های آموزش با ۲ پا

$$H_{\text{قهوه‌ای}} = p_{\text{قهوه‌ای}} H_{\text{قهوه‌ای}} + p_{\text{سبز}} H_{\text{سبز}} + p_{\text{رنگ}}$$

$$H_{\text{سبز}} = h_b(p_{\text{سبز},A}) = h_b\left(\frac{1}{2}\right) = 1$$

$$H_{\text{قهوه‌ای}} = h_b(p_{\text{قهوه‌ای},A}) = h_b\left(\frac{4}{5}\right) = 0.7219$$

$$\rightarrow H_{\text{رنگ}} = \frac{2}{7} H_{\text{سبز}} + \frac{5}{7} H_{\text{قهوه‌ای}} = 0.8014$$

$$H_{\text{کوتاه}} = p_{\text{کوتاه}} H_{\text{کوتاه}} + p_{\text{بلند}} H_{\text{بلند}}$$

$$H_{\text{بلند}} = h_b(p_{\text{بلند},A}) = h_b\left(\frac{1}{4}\right) = 0.8113$$

$$H_{\text{کوتاه}} = h_b(p_{\text{کوتاه},A}) = h_b\left(\frac{1}{3}\right) = 0.9183$$

$$\rightarrow H_{\text{قد}} = \frac{4}{7} H_{\text{کوتاه}} + \frac{3}{7} H_{\text{بلند}} = 0.8571$$

$$H_{\text{خشکی}} = p_{\text{خشکی}} H_{\text{خشکی}} + p_{\text{آب}} H_{\text{آب}}$$


$$H_{\text{آب}} = h_b(p_{\text{آب},A}) = h_b\left(\frac{1}{4}\right) = 0.8113$$

$$H_{\text{خشکی}} = h_b(p_{\text{خشکی},A}) = h_b\left(\frac{1}{3}\right) = 0.9183$$

$$\rightarrow H_{\text{محل زندگی}} = \frac{4}{7} H_{\text{آب}} + \frac{3}{7} H_{\text{خشکی}} = 0.8571$$

رنگ = گره میانی اول

در این صورت درخت بعد از مرحله اول مطابق با تصویر ۲-۱ خواهد شد.



تصویر ۱-۲: درخت تصمیم بعد از تشخیص گره میانی اول

حال داده‌های مربوط به هر شاخه را جدا می‌کنیم. مطابق با تصویر ۱-۲، ابتدا درخت در ادامه شاخه قهوه‌ای را مشخص می‌کنیم.

جدول ۳، داده‌های آموزش مربوط به جانداران ۲ پا و قهوه‌ای رنگ را نشان می‌دهد.

| شماره | قد | محل زندگی | جاندار |
|-------|-------|-----------|--------|
| ۱ | بلند | خشکی | A |
| ۵ | کوتاه | آب | A |
| ۶ | بلند | آب | A |
| ۷ | کوتاه | خشکی | B |
| ۱۰ | بلند | خشکی | A |

جدول ۳: داده‌های آموزش با ۲ پا و قهوه‌ای رنگ

$$H_{\text{قد}} = p_{\text{بلند}} H_{\text{بلند}} + p_{\text{کوتاه}} H_{\text{کوتاه}}$$

$$H_{\text{بلند}} = h_b(p_{\text{بلند}, A}) = h_b(1) = 0$$

$$H_{\text{کوتاه}} = h_b(p_{\text{کوتاه}, A}) = h_b\left(\frac{1}{2}\right) = 1$$

$$\rightarrow H_{\text{قد}} = \frac{2}{5} H_{\text{کوتاه}} + \frac{3}{5} H_{\text{بلند}} = 0.4$$

$$H_{\text{محل زندگی}} = p_{\text{آب}} H_{\text{آب}} + p_{\text{خشکی}} H_{\text{خشکی}}$$

$$H_{\text{آب}} = h_b(p_{\text{آب}, A}) = h_b(1) = 0$$

$$H_{\text{خشکی}} = h_b(p_{\text{خشکی}, A}) = h_b\left(\frac{1}{3}\right) = 0.9183$$

$$\rightarrow H_{\text{محل زندگی}} = \frac{4}{7} H_{\text{آب}} + \frac{3}{7} H_{\text{خشکی}} = 0.5510$$

قد = گره میانی I

حال مطابق با جدول ۴ داده‌های مربوط به رنگ سبز را جدا می‌کنیم و ویژگی گره II را بدست می‌آوریم.

| شماره | قد | محل زندگی | جاندار |
|-------|-------|-----------|--------|
| ۳ | بلند | آب | B |
| ۸ | کوتاه | آب | A |

جدول ۴: داده‌های آموزش با ۲ پا و سبز رنگ

$$H_{\text{قد}} = p_{\text{بلند}} H_{\text{بلند}} + p_{\text{کوتاه}} H_{\text{کوتاه}}$$

$$H_{\text{بلند}} = h_b(p_{\text{بلند}, A}) = h_b(1) = 0$$

$$H_{\text{کوتاه}} = h_b(p_{\text{کوتاه}, A}) = h_b(1) = 0$$

$$\rightarrow H_{\text{قد}} = \frac{1}{2} H_{\text{کوتاه}} + \frac{1}{2} H_{\text{بلند}} = 0$$

$$H_{\text{محل زندگی}} = p_{\text{آب}} H_{\text{آب}} + p_{\text{خشکی}} H_{\text{خشکی}}$$


$$H_{\text{آب}} = h_b(p_{\text{آب}, A}) = h_b\left(\frac{1}{2}\right) = 1$$

$$H_{\text{خشکی}} = h_b(p_{\text{خشکی}, A}) = h_b(1) = 0$$

$$\rightarrow H_{\text{محل زندگی}} = H_{\text{آب}} + 0 H_{\text{خشکی}} = 1$$

قد = گره میانی II

تصویر ۱-۳، درخت تصمیم بعد از مشخص شدن گره میانی های دوم را نشان می‌دهد.



تصویر ۱-۳: درخت تصمیم بعد از مشخص شدن گره میانی های دوم


جدول ۵، داده های آموزش برای جانداران ۲ پا، قهوه‌ای رنگ و کوتاه را نشان می‌دهد.

| شماره | محل زندگی | جاندار |
|-------|-----------|--------|
| ۵ | آب | A |
| ۷ | خشکی | B |

جدول ۵: داده های آموزش برای جانداران ۲ پا، قهوه‌ای رنگ و کوتاه

به همین ترتیب ویژگی گره آخر نیز که محل زندگی است مشخص می‌شود و همه داده های آموزش با این درخت تصمیم به درستی طبقه بندی می‌شوند.

تصویر ۱-۴، درخت تصمیم آموزش داده شده با الگوریتم ID3 را نشان می‌دهد.



تصویر ۱-۴: درخت تصمیم آموزش داده شده با الگوریتم ID3

قسمت ب: آزمون طبقه بند

در این قسمت می‌خواهیم ماتریس آشفتگی (confusion matrix) را برای داده‌های آزمون جدول ۶ بدست آوریم.

| شماره | رنگ | تعداد پا | قد | محل زندگی | جاندار |
|-------|---------|----------|-------|-----------|--------|
| ۱ | قهوه‌ای | ۳ | بلند | خشکی | B |
| ۲ | سبز | ۲ | بلند | خشکی | A |
| ۳ | سبز | ۲ | کوتاه | خشکی | A |
| ۴ | قهوه‌ای | ۲ | کوتاه | آب | B |
| ۵ | قهوه‌ای | ۲ | بلند | خشکی | A |

جدول ۶: داده‌های آزمون

برای هر کدام از داده‌های بالا با استفاده از درخت تصمیم قسمت اول برچسب جاندار را مشخص می‌کنیم و سپس با نوع جاندار (برچسب واقعی) مقایسه می‌کنیم.

درست $\rightarrow B$: برچسب $\rightarrow 3 =$ تعداد پا : شماره 1

غلط $\rightarrow B$: برچسب \rightarrow بلند : قد \rightarrow سبز : رنگ $\rightarrow 2 =$ تعداد پا : شماره 2

درست $\rightarrow A$: برچسب \rightarrow کوتاه : قد \rightarrow سبز : رنگ $\rightarrow 2 =$ تعداد پا : شماره 3

غلط $\rightarrow A$: برچسب \rightarrow آب : محل زندگی \rightarrow کوتاه : قد \rightarrow قهوه‌ای : رنگ $\rightarrow 2 =$ تعداد پا : شماره 4

درست $\rightarrow A$: برچسب \rightarrow بلند : قد \rightarrow قهوه‌ای : رنگ $\rightarrow 2 =$ تعداد پا : شماره 4

ماتریس آشفتگی (confusion matrix) درخت تصمیم برای داده‌های آزمون مطابق با تصویر ۵ خواهد بود.

| | | | |
|---------|---|------|---|
| | | True | |
| | | A | B |
| Predict | A | 2 | 1 |
| | B | 1 | 1 |

تصویر ۵-۱: ماتریس آشفتگی (confusion matrix)

همانطور که در تصویر ۵-۱ مشاهده می‌شود، عملکرد درخت تصمیم برای داده آزمون دقت معمولی دارد و ممکن است نتواند به خوبی برچسب جاندار را مشخص کند.

قسمت ج: رویکرد حریضانه الگوریتم ID3

نمی‌توان از دو ویژگی برای طبقه بندی جانداران استفاده کرد به طوری که خطا صفر شود. همانطور که در قسمت الف نیز بدست آمد، ۲ ویژگی بهتر اول تعداد پا و رنگ هستند و بعد از گره آن‌ها هنوز نوع جاندار مشخص نمی‌شود. زیرا احتمال مشترک بودن ۲ ویژگی برای ۲ جاندار متفاوت زیاد است. برای مثال جانداران شماره ۷ و ۱۰ از نظر رنگ و تعداد پا یکسان هستند اما برچسب یکسانی ندارند.

قسمت د: افزایش قوام طبقه بند

در هنگام آموزش طبقه بند درخت تصمیم بخاطر زیاد بودن داده های آموزش ممکن است علی رغم اینکه دقت طبقه بند روی داده های آموزش ۱۰۰٪ شود، دچار بیش برازش (overfitting) شود. دلیل این امر تعداد دفعات تقسیم کردن (splitting) و استفاده از داده های زیاد برای آموزش طبقه بند است.

از راهکار های مقابله با این مشکل می‌توان به دو مورد زیر اشاره کرد:

۱- صرف نظر از استفاده از همه داده های آموزش در فرایند تقسیم کردن (splitting)

۲- طراحی کلی درخت تصمیم و سپس حذف تعدادی از شاخه ها و گره های میانی

منبع:

- <https://towardsdatascience.com/construct-a-decision-tree-and-how-to-deal-with-overfitting-f907efc1492d>

سوال ۲: پیاده‌سازی الگوریتم درخت تصمیم

دادگان کشتی تایتانیک: از داده‌های تحت عنوان `train-data.csv`، ۸۰٪ را به عنوان داده آموزشی و ۲۰٪ را به عنوان داده آموزش انتخاب می‌کنیم. به این منظور از تابع `train_test_split` (کتابخانه `sklearn.model_selection`) استفاده می‌کنیم.

قسمت الف: پیاده‌سازی مدل درخت تصمیم

ویژگی‌های مؤثر در تشخیص نجات یافتگان کشتی تایتانیک: با توجه به ۷ ویژگی داده شده، مهم‌ترین ویژگی‌ها جنسیت، سن و همچنین تعداد افراد همراه می‌باشد. سایر ویژگی‌ها مثل بندر سوار شدن در تشخیص نجات یافتگان ممکن است خیلی مهم نباشند. برای طراحی درخت تصمیم سعی می‌کنیم از هر ۷ ویژگی استفاده کنیم. در نهایت به این نتیجه می‌رسیم که زیاد بودن ویژگی‌ها و وجود برخی ویژگی‌های غیر مؤثر باعث فرابرازش (`overfitting`) و پایین آمدن دقت درخت تصمیم می‌شود.

پیش پردازش داده‌ها: در این قسمت داده‌های پارامتری را به داده‌های عددی تبدیل می‌کنیم. برای مثال ۳ بندر سوار شدن به کشتی که `S`، `Q` و `C` هستند را با اعداد ۰، ۱ و ۲ مدل می‌کنیم. همچنین برای داده‌های از بین رفته در یک ویژگی (`NaN`) از میانه داده‌های آن ویژگی استفاده می‌کنیم.

الگوریتم طراحی درخت تصمیم: برای اینکه بتوانیم ویژگی‌ها را از حالت پیوسته و گسسته به حالت باینری ببریم، سعی می‌کنیم بین تمامی داده‌های هر ویژگی، مرزی را انتخاب کنیم که کمترین آنتروپی را نتیجه دهد. داده‌های کوچکتر از مرز را با ۰ و داده‌های بزرگتر از مرز را با ۱ مشخص می‌کنیم. سپس به‌مانند بخش اول تمرین، در هر گره از درخت، سعی می‌کنیم ویژگی‌ای را انتخاب کنیم که منجر به کمترین آنتروپی شود. به عبارت دیگر بیشترین ابهام نسبت به برچسب داده برطرف شود. در نهایت گره‌های تعیین شده در هر طبقه را به هم متصل کرده و طبقه بندی را با استفاده از مرزهای مشخص شده انجام می‌دهیم. در الگوریتم کلی تعداد ماکزیمم طبقات درخت را به عنوان یکی از شروط توقف و رسیدن به برگ‌های درخت در نظر می‌گیریم و به همین منظور دقت و ماتریس آشفتگی (`confusion matrix`) را برای مقادیر مختلف تعداد طبقات درخت بدست می‌آوریم.

تصویر ۱-۲ دقت و ماتریس آشفستگی را برای تعداد طبقات مختلف درخت نشان می‌دهد. همانطور که مشاهده می‌شود در صورتی که تعداد طبقات را کم در نظر بگیریم چون از ویژگی‌های کمتری در طبقه‌بندی استفاده کرده‌ایم دقت کمی داریم. از طرف دیگر اگر تعداد طبقات خیلی زیاد شود، طبقه‌بند مقاومت خود را در برابر فرابرازش (overfitting) از دست می‌دهد و دقت آن روی داده‌های تست کمتر می‌شود.

Maximum Depth : 4
accuracy = 81.00558659217877 %
confusion matrix:
[[109 32]
[2 36]]

Maximum Depth : 3
accuracy = 79.3296089385475 %
confusion matrix:
[[109 35]
[2 33]]

Maximum Depth : 6
accuracy = 82.12290502793296 %
confusion matrix:
[[110 31]
[1 37]]

Maximum Depth : 5
accuracy = 81.56424581005587 %
confusion matrix:
[[110 32]
[1 36]]

Maximum Depth : 7
accuracy = 81.56424581005587 %
confusion matrix:
[[109 31]
[2 37]]

تصویر ۱-۲: ماتریس آشفستگی (confusion matrix) و دقت برای تعداد طبقات مختلف درخت تصمیم

قسمت ب: بهبود بخشی الگوریتم درخت تصمیم

همانطور که در بخش اول نیز گفته شد یکی از عواملی که با استفاده از آن می‌توان مانع از فرابرازش درخت تصمیم شد حذف برخی ویژگی‌ها است. می‌توانیم با حذف برخی ویژگی‌هایی که آنتروپی بیشتری دارند، دقت درخت تصمیم را افزایش دهیم. یکی دیگر از راهکارهای مناسب برای افزایش دقت درخت تصمیم، طراحی جنگل تصادفی است. در الگوریتم جنگل تصادفی هنگامی که می‌خواهیم درخت را آموزش دهیم، از تعداد دلخواهی داده آموزشی به صورت رندوم استفاده می‌کنیم. به این ترتیب تعدادی درخت (مثلاً ۱۰ درخت) را طراحی می‌کنیم. سپس برای طبقه‌بندی، بین برچسب‌های خروجی از هر درخت جنگل، رأی اکثریت گرفته و برچسب نهایی را تعیین می‌کنیم. در قسمت ج این الگوریتم را پیاده‌سازی می‌نمائیم.

قسمت ج: استفاده از جنگل تصادفی

مطابق با الگوریتم گفته شده در قسمت ب، جنگل تصادفی را با ۱۰ درخت تعریف می‌کنیم. تصویر ۲-۲ ماتریس آشفستگی (confusion matrix) را به همراه دقت جنگل تصادفی نشان می‌دهد.

```
Random Forest with 10 trees :  
accuracy = 82.68156424581005 %  
confusion matrix:  
[[109  29]  
 [  2 39]]
```

تصویر ۲-۲: ماتریس آشفتگی (confusion matrix) و دقت جنگل تصادفی

سوال ۳: یادگیری براساس معیار

*** طبقه بند k همسایه نزدیک

قسمت الف: طراحی طبقه بند

در این قسمت ابتدا به کمک ۸۰٪ داده‌ها (۱۳۶ داده)، تابع مربوط به طبقه بند kNN را می‌نویسیم. سپس ماتریس آشفتگی (confusion matrix) و دقت طبقه بند را برای مقادیر مختلف k بدست می‌آوریم. تصویر ۱-۳، ماتریس آشفتگی (confusion matrix) و دقت طبقه بند را برای مقادیر $k = 1, 5, 10, 20$ نشان می‌دهد.

```
(k = 1)
accuracy = 69.44444444444444 %
confusion matrix:
[[10  2  0]
 [ 0  8  4]
 [ 1  4  7]]
```

```
(k = 5)
accuracy = 69.44444444444444 %
confusion matrix:
[[10  3  0]
 [ 0  9  5]
 [ 1  2  6]]
```

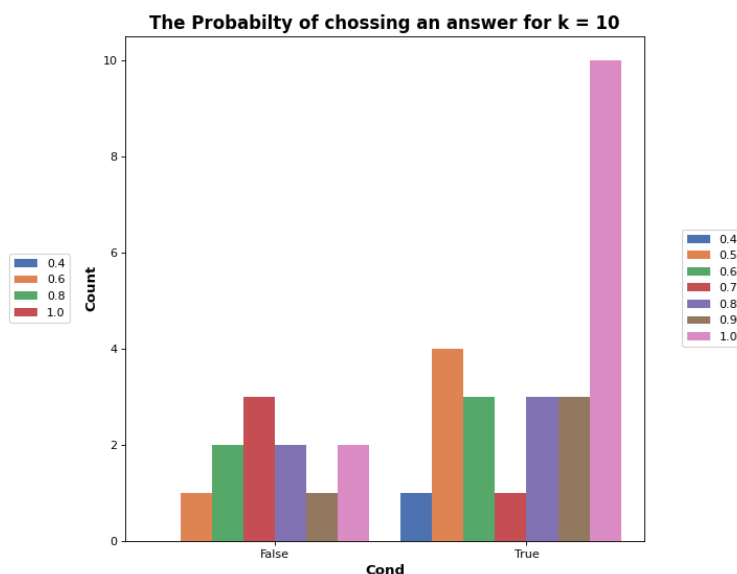

```
(k = 10)
accuracy = 63.888888888888886 %
confusion matrix:
[[11  3  1]
 [ 0  9  7]
 [ 0  2  3]]
```

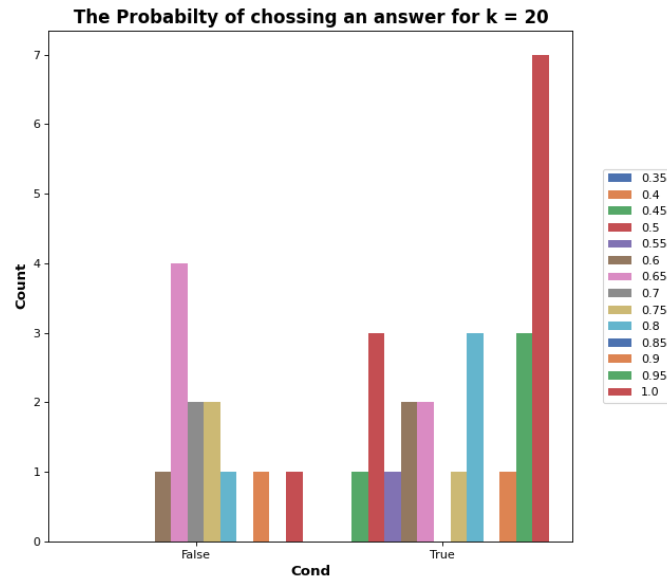
```
(k = 20)
accuracy = 80.55555555555556 %
confusion matrix:
[[11  3  1]
 [ 0 10  2]
 [ 0  1  8]]
```

تصویر ۱-۳: ماتریس آشفتگی (confusion matrix) و دقت طبقه بند برای مقادیر مختلف k

قسمت ب: محاسبه توزیع احتمال تعلق به هر کلاس

در این قسمت مطابق با خواسته مسئله تابع Prob_knn نوشته شده است. تصاویر ۲-۳ نمودار مربوط به احتمال تعلق به هر کلاس را به ازای $k = 5, 10, 20$ نشان می‌دهد.





تصویر ۳-۲: نمودار مربوط به احتمال تعلق به هر کلاس را به ازای $k = 5, 10, 20$

همانطور که در تصویر ۳-۱ و ۳-۲ مشاهده می‌شود، برای مقادیر خیلی کوچک k ($k = 1$)، دقت خیلی مناسب نیست. زیرا احتمال اینکه یک داده تست نزدیک به یک داده آموزش غیرهمکلاس باشد وجود دارد. علاوه بر آن اگر k خیلی بزرگ شود، ممکن است دچار خطا شویم. برای مثال در صورتی که تعداد داده های آموزش از یک کلاس در یک موقعیت خاص کم باشد، برای یک k بزرگ، از کلاس مخالف داده های زیادی در محدوده داده تست قرار می‌گیرد و خطا رخ می‌دهد.

*** یادگیری بر اساس معیار

قسمت الف: بررسی کارکرد روش یادگیری

هدف از این دو روش، انتقال دادگان به فضای جدیدی است که داده های مربوط به هر دو کلاس مختلف فاصله بیشتری تا هم داشته باشند. به این منظور در هر روش یک مسئله بهینه سازی به همراه قیود تعریف می‌شود.

در ابتدا معیار Mahalanobis metric را بصورت زیر تعریف می‌کنیم:

$$d(\vec{x}_i, \vec{x}_j) = (\vec{x}_i - \vec{x}_j)^T M (\vec{x}_i - \vec{x}_j)$$

*** روش LMNN (Largest Margin Nearest Neighbor):

در این روش برای تعریف دادگان در فضای جدید، ابتدا برای یک داده تعداد k داده نزدیک را مشخص می‌کنیم و سپس داده های هم‌کلاس را نزدیک و داده های کلاس های مخالف را دور می‌کنیم.

حال مسئله بهینه سازی را به صورت زیر تعریف می‌کنیم. (λ یک ثابت مثبت و M یک ماتریس معین مثبت (قید III) است).

$$\min_m \sum_{i,j \in N_i} d(x_i, x_j) + \lambda \sum_{i,j,l} \xi_{ijl}$$

$$(I) \quad d(x_i, x_l) - d(x_i, x_j) \geq 1 - \xi_{ijl}, \quad \forall i, j \in N_i, \quad l: y_i \neq y_l$$

$$(II) \quad \xi_{ijl} \geq 0$$

$$(III) \quad M \geq 0$$

قید (I) و (II) بیان می‌کند که می‌خواهیم علاوه بر کم کردن فاصله داده‌های کلاس مشابه به هم، داده‌های کلاس‌های مخالف را دور کنیم.

*** روش LFDA (Local Fisher Discriminant Analysis):

در این روش برای تعریف دادگان در فضای جدید، سعی می‌کنیم به داده‌های هم‌کلاس وزن دهیم و به همین ترتیب آنها را در موقعیتی مستقل تر قرار دهیم. (در این روش همبستگی ویژگی‌های داده‌های دو کلاس مختلف تقریباً صفر می‌شود).
به این ترتیب دو ماتریس را برای مسئله بهینه‌سازی به صورت زیر تعریف می‌کنیم.

$$A_{i,j}^{(\omega)} = \begin{cases} \frac{A_{i,j}}{n_c}, & \text{if } y_i = y_j = c \\ 0, & \text{if } y_i \neq y_j \end{cases}$$

$$A_{i,j}^{(\omega)} = \begin{cases} A_{i,j} \left(\frac{1}{n} - \frac{1}{n_c} \right), & \text{if } y_i = y_j = c \\ \frac{1}{n}, & \text{if } y_i \neq y_j \end{cases}$$

n_c تعداد داده‌های کلاس c و n تعداد کل داده‌ها را نشان می‌دهد.

$$S^{(W)} = \frac{1}{2} \sum_{i,j=1}^n A_{i,j}^{(\omega)} (x_i - x_j)(x_i - x_j)^T$$

$$S^{(B)} = \frac{1}{2} \sum_{i,j=1}^n A_{i,j}^{(b)} (x_i - x_j)(x_i - x_j)^T$$

حال مسئله بهینه‌سازی را به صورت زیر تعریف می‌کنیم.

$$T_{LFDA} = \operatorname{argmax}_T \left[\operatorname{trace} \left((T^T S^{(W)} T)^{-1} T^T S^{(B)} T \right) \right]$$

در نهایت با استفاده از T_{LFDA} به دست آمده، داده‌ها را به صورت زیر به فضای جدید تصویر می‌کنیم. (Z_i ها بیانگر داده‌های تصویر شده‌اند).

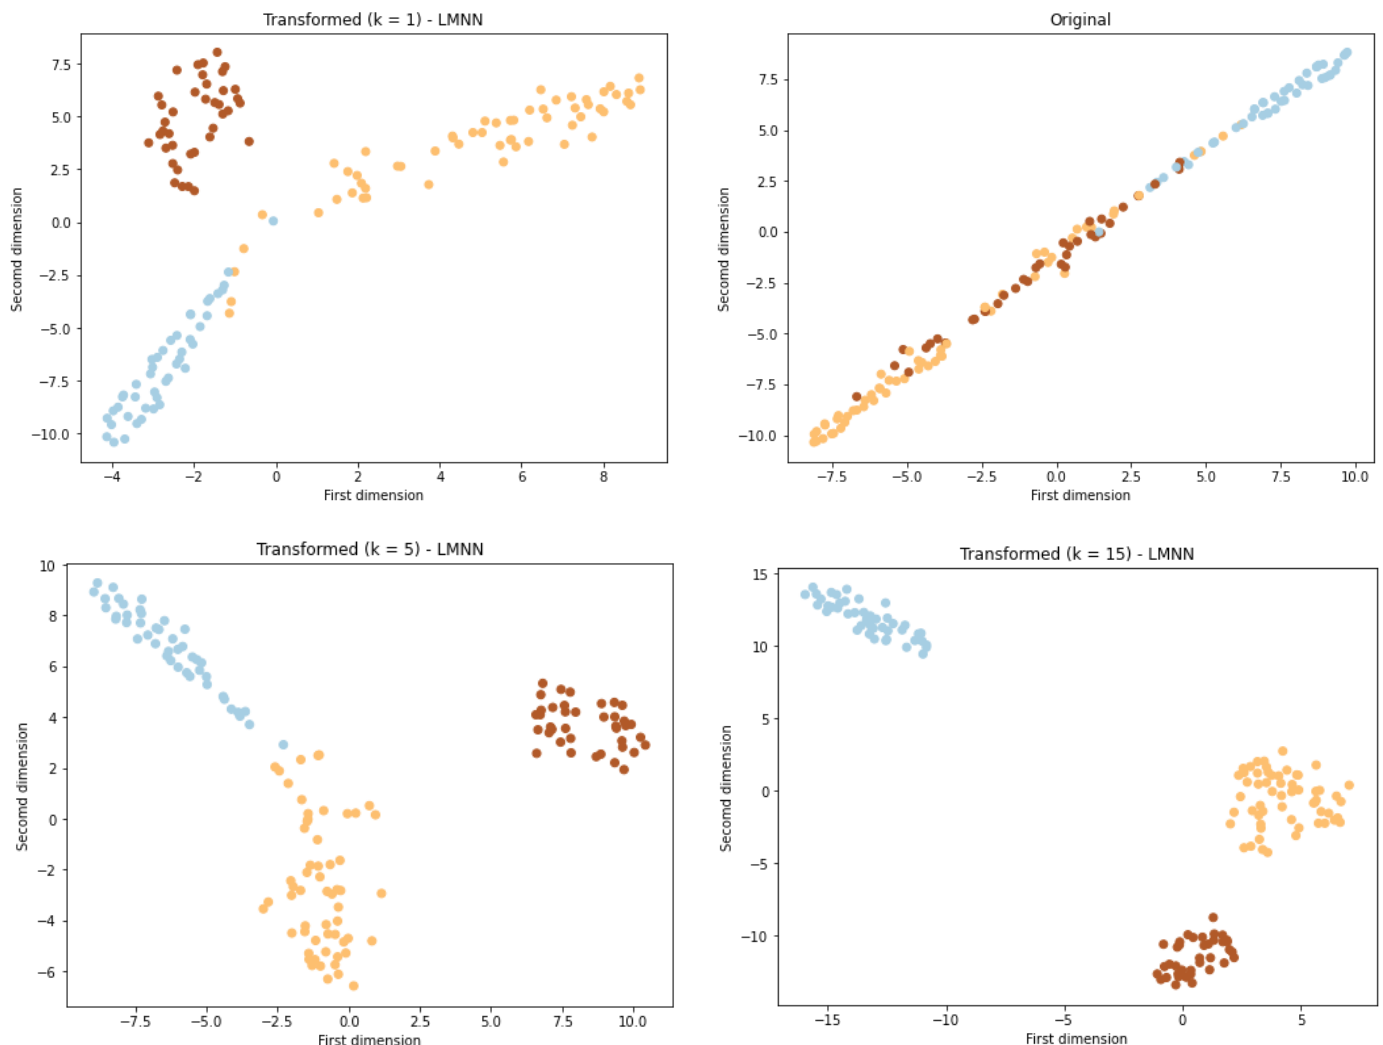
$$Z_i = T_{LFDA}^T x_i$$

قسمت ب: ترسیم دادگان انتقال یافته در فضای جدید

سوال ۱. در دو روش یادگیری بحث شده، k تعداد نزدیک‌ترین همسایه‌های به داده منتخب هستند که سعی می‌کنیم داده‌های هم‌کلاس را به هم نزدیک و داده‌های مخالف را از آن دور کنیم. اما در طبقه‌بند kNN سعی می‌کنیم با استفاده از اکثریت کلاس‌های k داده نزدیک، کلاس داده تست را مشخص کنیم.

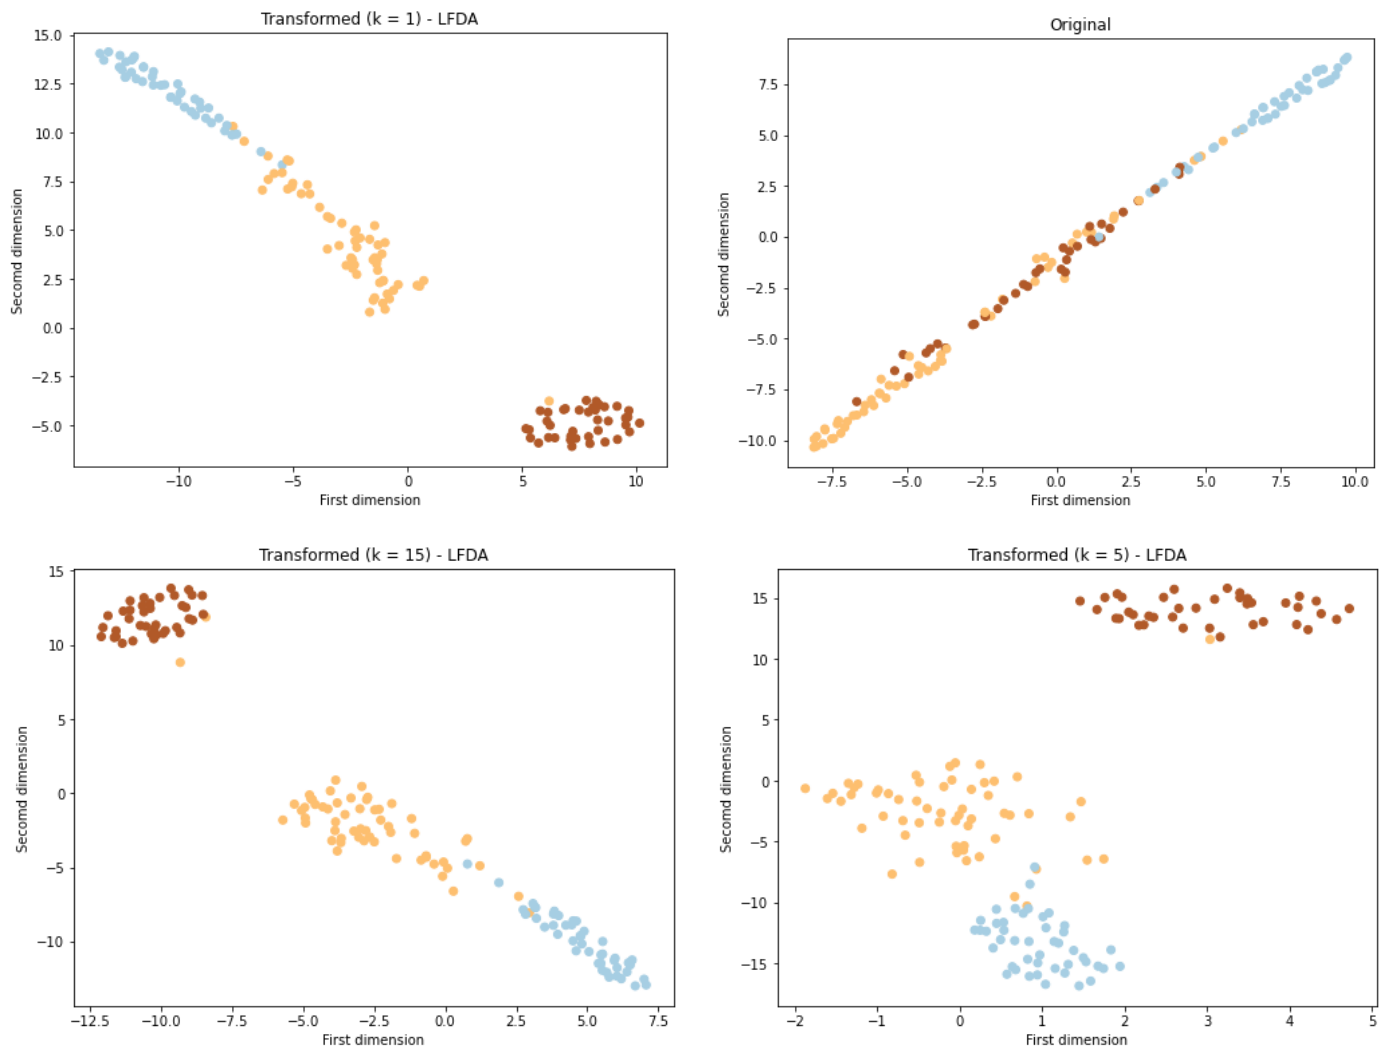
سوال ۲. ابتدا داده‌های اصلی (با ۱۳ بعد) را با استفاده از روش PCA، به فضای با تعداد بعد پایین‌تر (۲ بعد) انتقال می‌دهیم. سپس با استفاده از روش‌های یادگیری LMNN و LFDA، داده‌ها را به فضای جدید و با تعداد کمتر (به کمک آرگومان $n_components$ در دستور مربوط به روش LMNN یا LFDA می‌بریم).

تصاویر ۳-۳، نمودارهای دادگان در فضای ۲ بعد با روش LMNN را نشان می‌دهد.



تصویر ۳-۳: نمودار دادگان در فضای تقلیل یافته با استفاده از روش LMNN

تصاویر ۴-۳، نمودارهای دادگان در فضای ۲ بعد با روش LFDA را نشان می‌دهد.



تصویر ۳-۴: نمودار داده‌ها در فضای تقلیل یافته با استفاده از روش LFDA

همانطور که در تصاویر ۳-۳ و ۳-۴ مشاهده می‌شود، بهترین مقدار k ، برای هر دو روش LMNN و LFDA، مقدار $k = 15$ می‌باشد. زیرا در این حالت تعداد نقاط تصمیم‌گیری برای نزدیک شدن به کلاس داده‌ی منتخب یا دور شدن از آن زیادتر است و دسته‌ها جدا تر نسبت به هم قرار می‌گیرند.

قسمت ج: مقایسه عملکرد طبقه‌بند

حال داده‌های تست را با استفاده از ماشین آموزش داده شده با روش‌های LFDA و LMNN به فضای جدید انتقال می‌دهیم و از طبقه‌بند kNN در قسمت قبل برای مشخص کردن برچسب آن‌ها استفاده می‌کنیم.

تصویر ۳-۵، دقت و ماتریس آشفتگی را برای ماشین آموزش داده شده با استفاده از روش LMNN را نشان می‌دهد.

```
LMNN: (k = 1)
accuracy = 100.0 %
cofusion matrix:
[[12  0  0]
 [ 0 16  0]
 [ 0  0  8]]
```

```
LMNN: (k = 5)
accuracy = 100.0 %
cofusion matrix:
[[12  0  0]
 [ 0 16  0]
 [ 0  0  8]]
```

```
LMNN: (k = 10)
accuracy = 100.0 %
cofusion matrix:
[[12  0  0]
 [ 0 16  0]
 [ 0  0  8]]
```

```
LMNN: (k = 20)
accuracy = 100.0 %
cofusion matrix:
[[12  0  0]
 [ 0 16  0]
 [ 0  0  8]]
```

تصویر ۳-۵: دقت و ماتریس آشفتگی را برای ماشین آموزش داده شده با استفاده از روش LMNN

تصویر ۳-۶، دقت و ماتریس آشفتگی را برای ماشین آموزش داده شده با استفاده از روش LFDA را نشان می‌دهد.

```
LFDA: (k = 1)
accuracy = 97.2222222222221 %
cofusion matrix:
[[12  1  0]
 [ 0 15  0]
 [ 0  0  8]]
```

```
LFDA: (k = 10)
accuracy = 100.0 %
cofusion matrix:
[[12  0  0]
 [ 0 16  0]
 [ 0  0  8]]
```

```
LFDA: (k = 5)
accuracy = 97.2222222222221 %
cofusion matrix:
[[11  0  0]
 [ 1 16  0]
 [ 0  0  8]]
```

```
LFDA: (k = 20)
accuracy = 100.0 %
cofusion matrix:
[[12  0  0]
 [ 0 16  0]
 [ 0  0  8]]
```


تصویر ۳-۶: دقت و ماتریس آشفتگی را برای ماشین آموزش داده شده با استفاده از روش LFDA

همانطور که در تصاویر ۳-۵ و ۳-۶، مشاهده می‌شود بعد از انتقال دادگان به فضای دو بعدی با استفاده از روش های یادگیری LFDA و LMNN داده ها از هم جدا شده و موقعیت بهتری نسبت به هم دارند. در نتیجه طبقه بند kNN عملکرد بهتری خواهد داشت و دقت آن بسیار بهتر خواهد شد.

قسمت د: ضریب همبستگی


در این قسمت ابتدا برای داده های اولیه (خام) و انتقال یافته به هر دو روش یادگیری، ماتریس همبستگی را بدست می‌آوریم. به این منظور ابتدا داده ها و ویژگی های آن‌ها را به یک DataFrame تبدیل کرده و سپس از دستور `corr()` برای بدست آوردن ماتریس همبستگی استفاده می‌کنیم. در نهایت با استفاده از دستور heatmap (کتابخانه seaborn) این ماتریس را رسم می‌کنیم.

تصویر ۳-۷: ماتریس همبستگی برای داده های خام را نشان می‌دهد.



تصویر ۳-۷: ماتریس همبستگی ویژگی‌ها برای داده های خام


تصویر ۳-۸: ماتریس همبستگی برای داده های انتقال یافته به فضای جدید به روش LMNN را نشان می‌دهد.



تصویر ۳-۸: ماتریس همبستگی ویژگی‌ها برای داده های انتقال یافته به فضای جدید به روش LMNN

همانطور که در تصاویر ۳-۸ مشاهده می‌شود، مقادیر ماتریس همبستگی بعد از انتقال تصاویر به فضای جدید (۱۳ بعدی) با روش LMNN، به نسبت قبل بزرگتر شده است. در نتیجه می‌توان گفت با این روش یادگیری با افزایش همبستگی ویژگی‌ها به هم، جداسازی کلاس‌های مختلف آن‌ها را فراهم می‌کند.

تصویر ۳-۹ ماتریس همبستگی برای داده‌های انتقال یافته به فضای جدید به روش LFDA را نشان می‌دهد.



تصویر ۳-۹: ماتریس همبستگی ویژگی‌ها برای داده‌های انتقال یافته به فضای جدید به روش LFDA

همانطور که در تصاویر ۳-۹ مشاهده می‌شود، مقادیر ماتریس همبستگی بعد از انتقال تصاویر به فضای جدید (۱۳ بعدی) با روش LFDA، روی قطر اصلی بزرگتر است. در نتیجه می‌توان گفت با این روش یادگیری توانسته ایم تا حدودی ویژگی‌ها را از یکدیگر مستقل کنیم.

قسمت ه: GMML

در این روش سعی می‌شود با تغییر در تعریف مسئله بهینه‌سازی LMNN در قسمت الف، بتوانیم داده‌ها را بهتر در فضای جدید تصویر کنیم. به این منظور مسئله بهینه‌سازی به صورت زیر تعریف می‌شود. (S بیانگر داده‌های هم‌کلاس و D بیانگر داده‌های مخالف است).

$$A = \underset{A}{\operatorname{argmin}} \sum_{(x_i, x_j) \in S} \operatorname{tr} [A(x_i - x_j)(x_i - x_j)^T] + \sum_{(x_i, x_j) \in N} \operatorname{tr} [A^{-1}(x_i - x_j)(x_i - x_j)^T]$$